

Plan de acción

f1-data-platform · alternativas y camino recomendado

30 de septiembre de 2026 · basado en el *Informe de situación del proyecto* ([docs/informe_situacion/build/informe.pdf](#))

En una página

- El informe no encuentra nada roto de gravedad: la plataforma funciona, está desplegada y sus pruebas pasan. Lo que hay son **riesgos operativos baratos de quitar, errores de datos concretos, datos disponibles que no se usan** y una web que **replica bien el TFG pero no cuenta aún las carreras**.
- Se proponen **cuatro caminos** alternativos: (A) consolidar y ampliar, (B) escaparate visual primero, (C) directo a la fase 7 y (D) portfolio de arquitectura. Todos comparten un **tronco común** de unos 3 días que conviene hacer en cualquier caso.
- **Recomendación: camino A**, en unas 8 semanas de trabajo efectivo, con dos puntos de decisión donde se puede derivar hacia B o C. Deja la fase 7 sobre datos sólidos (meteorología, compuesto real, neutralizaciones bien marcadas) y la web con las visualizaciones que más valor aportan en la defensa.
- Necesito de ti **seis decisiones** (sección 6) antes de empezar; para el tronco común solo hace falta la primera (licencia).

Índice general

1.	Lectura crítica del informe	2
2.	Bloques de trabajo	2
2.1.	Tronco común (en cualquier camino)	4
3.	Caminos alternativos	4
4.	Plan recomendado: camino A, semana a semana	5
5.	Variantes de alcance	6
6.	Decisiones que necesito de ti	6
7.	Riesgos y cómo mitigarlos	7
8.	Qué no hacer, por ahora	7

1 Lectura crítica del informe

Antes de planificar he revisado el informe completo buscando contradicciones entre notas, dependencias ocultas entre propuestas y cifras que conviene confirmar.

Correcciones y matices

- **Race trace: desde 1990, no desde 1950.** El catálogo externo lo daba por factible desde 1950; en la base no hay tiempos por vuelta ni diferencias antes de 1990 (menos del 1,5 % por década). Ya está corregido en el informe. El diferencial real es el lap chart desde 1950 y el race trace desde 1990.
- **Unit tests de dbt.** Una nota cuenta 4 y otra 2; en el código hay 2 en `_quality__models.yml`. Lo relevante coincide en ambas: ninguno cubre la fusión de vueltas ni la numeración, que es la lógica más delicada.
- **Tamaño de la base.** `f1.duckdb` pesa 54,5 MB, no unos 200 MB. Esto abarata cualquier alternativa (meter la base en la imagen Docker, servirla estática, DuckDB-WASM).
- **Cifras de planes gratuitos** (Koyeb, Render, GitHub Pages) proceden en parte de agregadores: hay que confirmarlas en la web oficial antes de migrar nada.
- **La API sin caché de página en Vercel** está diagnosticada pero no confirmada: la causa probable (rutas dinámicas sin `generateStaticParams` o `fetch` sin caché) hay que verificarla con la salida de `next build`.

Dependencias que condicionan el orden

1. **El cambio de grano de `fact_laptimes`** (columna `session_type` para los sprints) afecta a todos los consumidores de vueltas: API, race trace, degradación. Conviene hacerlo *antes* de construir gráficos o modelos nuevos sobre las vueltas, o todos tendrán que revisarse después.
2. **La fase 7 depende de tres huecos de datos:** compuesto real C1–C6 desde 2024, meteorología y neutralizaciones bien marcadas (la bandera roja cae una vuelta antes en 22 carreras). Empezar la analítica sin ellos obliga a rehacerla.
3. **La arquitectura B** (API estática) reutiliza las consultas de la API. Hacerla antes de estabilizar la API (`driver_number, ?session=sprint`) supone exportar dos veces.
4. **La navegación de 5 pestañas** decide dónde van los gráficos nuevos. Si se añaden gráficos antes de reorganizarla, habrá que moverlos.
5. **Integrar Jolpica u OpenF1** requiere antes decidir la licencia (CC BY-NC-SA obliga a publicar lo derivado en las mismas condiciones).

Lo que no necesita decisión

Hay un conjunto de tareas que ningún camino discute y que reducen riesgo inmediatamente. Forman el **tronco común** (sección 2.1).

2 Bloques de trabajo

Cada bloque es una unidad que se puede planificar, entregar y verificar por separado. Los caminos de la sección 3 son combinaciones y órdenes distintos de estos bloques.

Id	Contenido	Días	Depende	Terminado cuando
T1	Higiene: LICENSE y atribuciones; Dependabot; acciones fijadas a SHA y fuera de Node 20; cabeceras de seguridad; fetch con timeout y reintento; ruff de pre-commit alineado; región fra1 en Vercel	1–1,5	D1	CI verde sin avisos de Node 20; cabeceras visibles en producción
T2	Robustez operativa: releases fechadas e inmutables además de data-latest; copia del bronze estático; prueba de humo de la API antes de publicar; arranque de la API con la última copia si falla GitHub; /health con fecha de datos	1,5–2	—	Un pipeline con datos rotos no publica; la API arranca sin GitHub
T3	Arreglos de datos rápidos: has_sprint; bandera roja en la vuelta que contiene la suspensión; tiempo por suma de sectores (570 vueltas); NAN/NONE a nulo; HUGEINT; tabla huérfana; recargar Italia 2018 en FastF1	1	—	QA sin regresiones; São Paulo 2024 v. 33 marcada
C1	Correcciones visibles: driver_number en /laps y /stints; abreviaturas únicas por carrera; dorsales solo de sesiones de carrera; desempate determinista en int_lap_numbering	1,5–2	T3	Ningún duplicado de grano; Schumacher M./R. distinguibles
C2	Pruebas: unit tests de int_laptimes, int_lap_numbering y parse_duration_ms; tests de clave y relación en paradas, standings, agregados y telemetría	2	C1	Los tests fallan si se rompe la fusión
C3	Errores de lectura de la web: referencia de clasificación explícita; eje continuo de temporadas; constructores sin barras antes de 1958; etiquetas finales sin solaparse; formato español en ejes; paradas con eje ajustado y rótulo «tiempo en pit lane»; violín legible	2	—	Revisión visual en escritorio y 375 px; Playwright + axe en verde
D1	FastF1 ampliado: sesiones S/SQ/SS/FP, weather, messages; modelos de meteorología y dirección de carrera	2–3	T2	Meteo y mensajes 2018+ en gold
D2	Jolpica como segunda fuente (sustituye el volcado Ergast 2022)	1–2	D0 (licencia)	2023–2026 con validation_status distinto de single_source
D3	Eventos históricos SC/VSC/rojas (seed desde RaceData) y nominaciones Pirelli C1–C6 (seed manual)	3	—	Banderas rojas 1950+; compuesto real 2024+
S1	Sprints: session_type en hechos de vueltas, int_sprint_laptimes con vuelta 1 derivada, ?session=sprint en la API, selector en la web	4 (mínimo) a 6–8 (con validación)	D1, C2	Los 29 sprints con lap chart, estrategia y ritmo
W1	Navegación: 5 pestañas de carrera (telemetría en Clasificación; Neumáticos + Boxes = Estrategia); pilotos seleccionados en la URL; enlaces cruzados	3	C3	5 pestañas caben en 375 px
W2	Tanda 1 de gráficos: race trace (1990+); franjas SC/VSC/rojas; matriz de resultados de temporada; récords ampliados; diferencia con el líder y eliminación matemática; KPIs de relato	6–8	W1, T3	Cada gráfico con resumen, tabla y prueba axe
W3	Tanda 2: página de circuito; comparador de dos pilotos; parrilla → V1 → llegada; campeonatos con otros sistemas de puntos; detector de undercut	7–9	W2	Rutas nuevas con pruebas e2e
W4	Tanda 3 (originales): red de compañeros; ghost race accesible; streamgraph de constructores; ADN del piloto; línea de títulos	6–10	W2	—

Id	Contenido	Días	Depende	Terminado cuando
A1	Arquitectura A: <code>justfile</code> ; sources dbt de todo el bronze con <code>freshness</code> ; subcarpetas en <i>intermediate</i> ; disparo diario por calendario y <i>keepalive</i>	2–3	T2	<code>just build</code> reproduce el pipeline local
A2	Arquitectura B: <code>export-static</code> , GitHub Pages, cliente con <code>F1_DATA_BASE_URL</code> y revalidación bajo demanda	6–9	A1, C1, S1	La web funciona con la API apagada
F0	Preparación de la fase 7: vueltas limpias (sin neutralización ni boxes), corrección de combustible, categorías de abandono (seed), telemetría 2018–2023	3–4	D1, D3	Tabla de vueltas limpias validada
F1	Fase 7: degradación, predicción de resultado, estilos de pilotaje	—	F0	Según su propio plan

2.1 Tronco común (en cualquier camino)

T1 + T2 + T3, unos 3,5–4,5 días. Son arreglos de bajo riesgo que eliminan los tres puntos frágiles señalados por el informe (release sobrescrita, publicación sin prueba de humo, falta de licencia), corrigen los errores de datos más visibles (sprints ocultos, bandera roja) y quitan los avisos de la CI. Ningún camino gana nada retrasándolos.

3 Caminos alternativos

A · Consolidar y ampliar (recomendado)

Secuencia: tronco → C1 → C2 → D1 → D2 → D3 → S1 → C3 → W1 → W2 → A1 → F0 → (A2 opcional) → F1.

Duración: unas 8 semanas hasta F0; A2 añade 1,5–2.

A favor: ataca las dependencias en su orden natural (grano de vueltas antes que gráficos y modelos; datos antes que analítica); cada entrega deja el sistema mejor y verificable; la fase 7 empieza sobre datos que se pueden defender.

En contra: la web no cambia de forma visible hasta la semana 4–5.

Elegirlo si la prioridad es la solidez del proyecto y la defensa técnica.

B · Escaparate visual primero

Secuencia: tronco → C3 → W1 → W2 → W3 → C1 → C2 → D1 → S1 → ...

Duración: unas 4 semanas hasta tener tandas 1 y 2 publicadas.

A favor: el cambio se ve enseguida; el race trace y la página de circuito son lo más vistoso.

En contra: los gráficos se construyen sobre un grano de vueltas que cambiará con los sprints (habrá que revisarlos) y sobre datos con errores aún abiertos (coches compartidos, abreviaturas); el race trace de 2025–26 hereda los huecos de fuente única.

Elegirlo si hay una fecha próxima para enseñar la web (defensa, entrevista, portfolio).

C · Directo a la fase 7

Secuencia: tronco → D1 → D3 → F0 → F1, dejando la web y los sprints para después.

Duración: unas 2,5 semanas hasta empezar la analítica.

A favor: la parte más novedosa del proyecto llega antes.

En contra: sin C2 la analítica se apoya en una fusión de vueltas sin pruebas; sin S1 el cambio de grano

llega después y obliga a revisar los modelos; la web sigue con sus errores de lectura.
Elegirlo si la fase 7 es el objetivo principal de esta etapa y la web puede esperar.

D · Portfolio de arquitectura

Secuencia: tronco → A1 → C1 → A2 → (Dagster + R2 + DuckLake experimental) → resto.

Duración: 3–4 semanas; 6–8 con la arquitectura C.

A favor: elimina el arranque en frío y da un argumento de diseño muy claro; aporta herramientas valoradas (orquestrador, lakehouse).

En contra: no mejora los datos ni lo que ve el usuario; la arquitectura C no la exige la necesidad real y añade proveedores y mantenimiento.

Elegirlo si el proyecto se va a usar sobre todo como muestra de ingeniería de datos.

Comparación

Criterio	A · Consolidar	B · Visual	C · Fase 7	D · Arquitectura
Semanas hasta el objetivo	8	4	2,5	3–4
Cambio visible en la web	semana 4–5	semana 1–2	tardío	bajo
Calidad de datos al final	alta	media	media	media
Retrabajo esperado	bajo	medio (sprints, datos)	medio (grano, tests)	bajo
Riesgo técnico	bajo	bajo	medio	medio–alto (con C)
Valor para la defensa	muy alto	alto	alto	alto
Prepara la fase 7	sí	no	parcialmente	no

4 Plan recomendado: camino A, semana a semana

Las semanas son de trabajo efectivo (unos 5 días); si el ritmo es a tiempo parcial, la secuencia es la misma y solo se estira el calendario.




Figura 1: Calendario orientativo del camino A. Azul: calidad; verde: datos; naranja: web; morado: arquitectura y preparación de la fase 7. A2 (API estática) y las tandas W3 y W4 quedan detrás, según lo que se decida en los hitos.

Semana 1 · Tronco común

T1, T2 y T3. Al acabar, el pipeline no publica una base rota, las releases quedan fechadas, la API arranca aunque GitHub falle, la CI no avisa de Node 20 y los 12 sprints de 2021–2023 aparecen en la web.

Semana 2 · Corrección y pruebas → Hito 1: «plataforma fiable»

C1 y C2. Punto de decisión: si surge una fecha para enseñar la web, derivar al camino B desde aquí (C3 → W1 → W2) y retomar los datos después.

Semanas 2–3 · Datos nuevos → Hito 2: «datos completos 2018+»

D1, D2 y D3. Al acabar: meteorología y dirección de carrera desde 2018, segunda fuente en 2023–2026, banderas rojas históricas y compuesto real. Punto de decisión: si la prioridad pasa a ser la fase 7, saltar a F0 desde aquí (camino C con base sólida).

Semanas 4–5 · Sprints y web

S1 (con el cambio de grano de vueltas hecho antes de cualquier gráfico nuevo), C3 y W1.

Semanas 5–7 · Tanda 1 de gráficos → Hito 3: «la web cuenta las carreras»

Race trace, franjas de neutralización, matriz de resultados, récords ampliados, eliminación matemática y KPIs de relato.

Semana 8 · Arquitectura A y preparación de la fase 7 → Hito 4

`justfile`, sources completos, disparo por calendario; vueltas limpias y variables para la degradación. A partir de aquí: fase 7, o A2 si el arranque en frío sigue molestando.

5 Variantes de alcance

Alcance	Qué incluye	Duración
Mínimo	Tronco común + C1 + C3 + sprints mínimos (S1 solo FastF1)	2–2,5 semanas
Estándar (recomendado)	Camino A hasta el hito 4	7–8 semanas
Ampliado	Estándar + A2 (API estática) + W3 (circuito, comparador)	11–13 semanas

6 Decisiones que necesito de ti

1. **Licencia** (D0, necesaria para el tronco): propuesta MIT para el código y CC BY 4.0 para los datos derivados, con atribución a F1DB, FastF1 y los datos © F1/FIA.
2. **¿Aceptas la cláusula no comercial (CC BY-NC-SA)** que implicaría integrar Jolpica y OpenF1? Si no, D2 se sustituye por validación interna sin publicar esos datos.
3. **Permiso para descargar volcados de terceros**: Jolpica (unos 14,5 MB) y, solo para validación interna, `f1resultsdatabase` (74 MB).
4. **Camino**: A (recomendado), B, C o D, y alcance (mínimo, estándar o ampliado).
5. **Cambio de región de Vercel a Frankfurt** (`fra1`): se hace desde el panel o con `vercel.json`; afecta al despliegue en producción.
6. **Navegación de 5 pestañas** y secciones nuevas (Circuitos, Comparar, Historia): ¿de acuerdo con la propuesta o prefieres mantener la estructura del TFG?

Además, quedan en tu mano: publicar la propuesta de correcciones a F1DB, activar la documentación de dbt en GitHub Pages y, si se elige la variante ampliada, confirmar los límites de los planes gratuitos en las webs oficiales.

7 Riesgos y cómo mitigarlos

Riesgo	Mitigación
El cambio de grano de <code>fact_laptimes</code> rompe consultas existentes	<code>session_type</code> con valor por defecto <code>race</code> ; filtro explícito en todas las consultas de la API; test de grano; hacerlo antes de W2
El backfill de FastF1 choca con el límite de 500 peticiones por hora Jolpica u OpenF1 cambian o desaparecen	Cargas por temporada repartidas en varias ejecuciones del pipeline; caché persistente Guardarlos en bronze versionado (releases fechadas); son fuentes de contraste, no primarias
La reclasificación de banderas rojas altera datos ya validados	QA antes y después; lista de las 22 carreras afectadas en el informe de calidad
Deriva de alcance en los gráficos	Tandas cerradas (W2, W3, W4) con criterio de terminado; nada de W3 hasta cerrar W2
Tiempo de desarrollo menor del previsto	El camino A se puede cortar en cualquier hito dejando el sistema coherente

8 Qué no hacer, por ahora

- Exportación estática completa de Next.js (unos 16 400 HTML; rompe los formularios sin JS).
- Migrar a Fly.io o Cloudflare Workers (sin plan gratuito o sin sitio para DuckDB).
- Nx o Turborepo (sobredimensionados).
- Buscar tiempos por vuelta anteriores a 1990: no hay fuente abierta; se documenta como limitación.
- Scraping de formula1db.com o statsf1.com: sus condiciones lo impiden.
- Arquitectura C (Dagster + R2 + DuckLake) antes de terminar el camino elegido.